Инструкция по разметке диминутивов KidLit v0.5

1. Назначение и единица разметки

Инструкция задает операциональную схему ручной разметки словоупотреблений и требования к детектору. Цель — воспроизводимая оценка суффиксальных диминутивных образований в KidLit. Схема не претендует на универсальную классификацию диминутивности.

Единица разметки — словоупотребление (токен из tokens.parquet). Лемма помогает, но решение принимается по слову в контексте: «ручки малыша» и «покрутил ручку» размечаются по-разному.

- **Что размечаем:** существительные, прилагательные и наречия с уменьшительно-ласкательными суффиксами, уменьшительные формы личных имен, названия детенышей.
- **Что не размечаем:** глаголы (например, «поспатеньки» фиксируем в комментарии, если встретится), сочетания слов, интонацию и «ласковость» текста в целом.
- Корпус: KidLit v0.2, 120 книг. В публичной версии инструкции цитаты из книг сокращены до четырех слов вокруг размечаемого слова; полный контекст восстанавливается по kidlit_id в собственной копии корпуса. Корпусные цитаты сопровождаются kidlit_id; примеры из адъюдикации — также adj_id. Схематические словообразовательные пары не являются цитатами из корпуса.
- **Главный принцип:** мы размечаем **живое словообразовательное отношение**, а не эмоцию. Диминутив не обязан быть ласковым: Воейкова (2020) показывает, что частые диминутивы выполняют и структурные функции, а Васильева и Резанова (2019), что эмоциональность нельзя приписывать по одному суффиксу.

2. Рабочее определение

В основном классе DIM размечаются синхронно соотносимые с производящим словом суффиксальные образования существительных, прилагательных и наречий. Суффикс выражает уменьшительность, оценку, смягчение или экспрессивную модификацию; явная ласка и физическая малость в каждом контексте не обязательны. Разговорная стилистическая окраска сама по себе недостаточна для DIM. Регистрируются четыре диагностических признака ниже. Закрытые исключения P-19 и P-23 обозначаются явно в поле precedent: решение P-19 входит в проверку

устойчивости результатов, а авторские образования P-23 единичны и выделяются по полю precedent.

1. Форма и функция. Выделяется суффикс с диминутивной или оценочной функцией. Совпадения букв и наличия однокоренного слова недостаточно. Перечень в разделе 6 предназначен для поиска кандидатов и не исчерпывает русский язык; исключения P-23 рассматриваются отдельно.
2. Производящее слово. Указывается ближайшее синхронно мотивирующее слово, обычно той же части речи: лапка → лапа, листочек → листок. Синоним или случайный результат отсечения не принимается. Смена части речи допускается только для перечисленных случаев P-23, с фиксацией исключения.
3. Семантическая соотнесенность. В контексте сохраняется базовое лексическое значение; меняется размер, оценка или прагматический оттенок. Для прилагательных и наречий проверяется признак или способ действия, а не предмет. Сначала учитывается переносное употребление всего выражения, затем отношение производного к базе. При устойчивом самостоятельном значении применяются контекстные прецеденты LEX. Принадлежность к подвиду предметов сама по себе не доказывает лексикализацию.
4. Стилистическая доступность базы. Книжность, разговорность или редкость базы является поводом для проверки, но не достаточное доказательство LEX. Сохраненные решения P-01, P-03 и P-22 являются закрытыми соглашениями KidLit; их нельзя автоматически распространять на новые слова. При споре фиксируются unsure и мотивировка.

Для обычного DIM должны выполняться признаки 1–3; признак 4 служит диагностикой и не является автоматическим запретом. Закрытые решения журнала применяются в указанной области действия, а не к любому омонимичному слову.

В статье KidLit by Numbers признаки даны в сокращенной форме как четыре условия DIM: есть диминутивный суффикс; есть современное производящее той же части речи; замена на производящее не меняет денотат; производящее стилистически нейтрально. Условие 4 в разметке применяется через закрытые соглашения P-01, P-03 и P-22, а не как автоматический запрет; в остальных случаях маркированная база — повод для unsure и адъюдикации.

Опора в литературе: прагматическая трактовка диминутива (Dressler, Merlini Barbaresi 2001), описание словообразовательных типов в «Русской

грамматике» (1980) и у Земской (1973), структурные функции и продуктивность моделей (Воейкова 2020), различие формы и воспринимаемой эмоциональности (Васильева, Резанова 2019).

Граница DIM/LEX в ряде случаев зависит от принятой исследовательской схемы. Для сопоставимости сохранены ранее утвержденные решения; прецеденты с ограниченным обоснованием и исключения P-19/P-23 маркируются; решения P-01, P-02 и P-19 включаются в анализ чувствительности, исключения P-23 выделяются по полю precedent. Это соглашения проекта, а не доказанные универсальные свойства слов.

3. Категории и атрибуты

Каждому кандидату присваивается ровно одна из пяти категорий. В подсчет «диминутивов» в статье идет только DIM; HYP и YOUNG анализируются отдельно.

Метка	Что это	Примеры из корпуса
DIM	Основной класс по признакам 1–3; P-19/P-23 — явно отмеченные исключения. Эмоциональность не обязательна.	«виднеется за холмом домик» (RUS-O_long_07); «уснули на солнышке» (RUS-O_long_06); «Мамочка, давай покатаемся» (RUS-O_long_07); «тихонько переговаривались» (RUS-O_medium_01); «как новенький» (RUS-O_medium_01)
LEX	Операциональный класс самостоятельных/нейтрализованных значений и закрытых пограничных решений проекта; не автоматическое утверждение об этимологии.	бабушка, девочка, кошка (название вида, а не «самка кота», см. P-20, тип 2), маленький, ветка; «покрутил ручку» радиостанции (RUS-O_long_07); «покатаемся с горки» (RUS-O_long_07)
HYP	Суффиксальная уменьшительная или фамильярная форма антропонима; носитель может быть человеком, животным или персонажем. P-09 содержит закрытое исключение Мишутка.	«Анька провинилась», «про медовую Аннушку» (RUS-O_long_25); Дениска, Петька, Вовка, Стасик; иноязычные: «медвежонок Тедди» (RUS-T_short_03) — с атрибутом foreign (P-14)
YOUNG	Название детеныша на -онок/-енок (мн. ч. -ата/-ята).	«сны мышатам снились» (RUS-O_long_06); лисенок, медвежонок, зайчонок, бельчонок
NO	Не входит в целевые классы: иная деривационная функция, простое слово, случайное совпадение сегментов или исключенная модель.	грузовик, летчик, подарок, кролик, лягушка, ребенок, щенок

LEX и NO разграничиваются по функции и закрепленному решению, а не только по наличию однокоренного слова. NO включает недиминутивную деривацию и случайные совпадения. LEX — операциональный класс лексикализованных/нейтрализованных и закрепленных пограничных единиц проекта. Историческое происхождение не устанавливается по языковому чутью. Доля LEX без независимой этимологической проверки не является долей исторически лексикализованных диминутивов.

Для -к- и сходных сегментов сначала устанавливается функция в конкретном значении (P-20). Единичность, феминитивность, отглагольная деривация и универбация не становятся DIM только из-за экспрессивного контекста. Закрытые исключения сохраняются с ID прецедента; при новой неоднозначности требуется адъюдикация.

Атрибуты (колонки таблицы разметки; base — у DIM, LEX, YOUNG и HYP по правилу P-17; pej и nonce — только у DIM; name — у DIM и YOUNG (P-25); foreign — только у HYP):

Атрибут	Значения	Пример
base	DIM — ближайшее морфологическое производящее; LEX — само слово; YOUNG — название взрослого животного; HYP — полное или краткое имя (P-17).	листочек → листок; кусочек → кусок; девочка → девочка; поросенок → свинья; Аннушка → Анна
pej	1 — пренебрежительная/уничижительная оценка подтверждена контекстом; 0 — не подтверждена после проверки. Суффикс лишь подсказка.	Зайчишка, муравьишки: DIM; pej определяется контекстом, а не автоматически по -ишк-.
name	1 — диминутив или название детеныша употреблены как имя персонажа (у DIM и YOUNG, P-25; у HYP не ставится).	«Старый Автомобильчик» (RUS-O_medium_01); «Малыш Колесик» (RUS-T_long_05)
nonce	Технический признак отсутствия леммы/проверяемой формы в фиксированном словаре; не доказательство авторского изобретения. Непроверенное значение остается пустым с unsure.	«четыре котофеечки» (RUS-O_long_26)
foreign	1 — иноязычная уменьшительная форма имени, заимствованная вместе с именем (только у HYP, P-14).	«медвежонок Тедди» (RUS-T_short_03)

4. Процедура решения

Порядок решения приведен ниже. Он обязателен для ручной разметки; детектор лишь приближает контекстные проверки и должен явно отмечать случаи, нуждающиеся в человеческой проверке.

Шаг 1. Прочитать предложение и при необходимости расширенный контекст; проверить токенизацию, часть речи и лемму.

Шаг 2. Проверить журнал: применить только подходящее значение и область действия прецедента. Неясный контекст не заменять леммным решением.

Шаг 3. Определить HYP по антропонимической базе, затем YOUNG по продуктивной модели детенышей; вторичная диминутивация (котеночек) относится к DIM.

Шаг 4. Проверить морфемную функцию и признаки DIM, включая закрытые исключения.

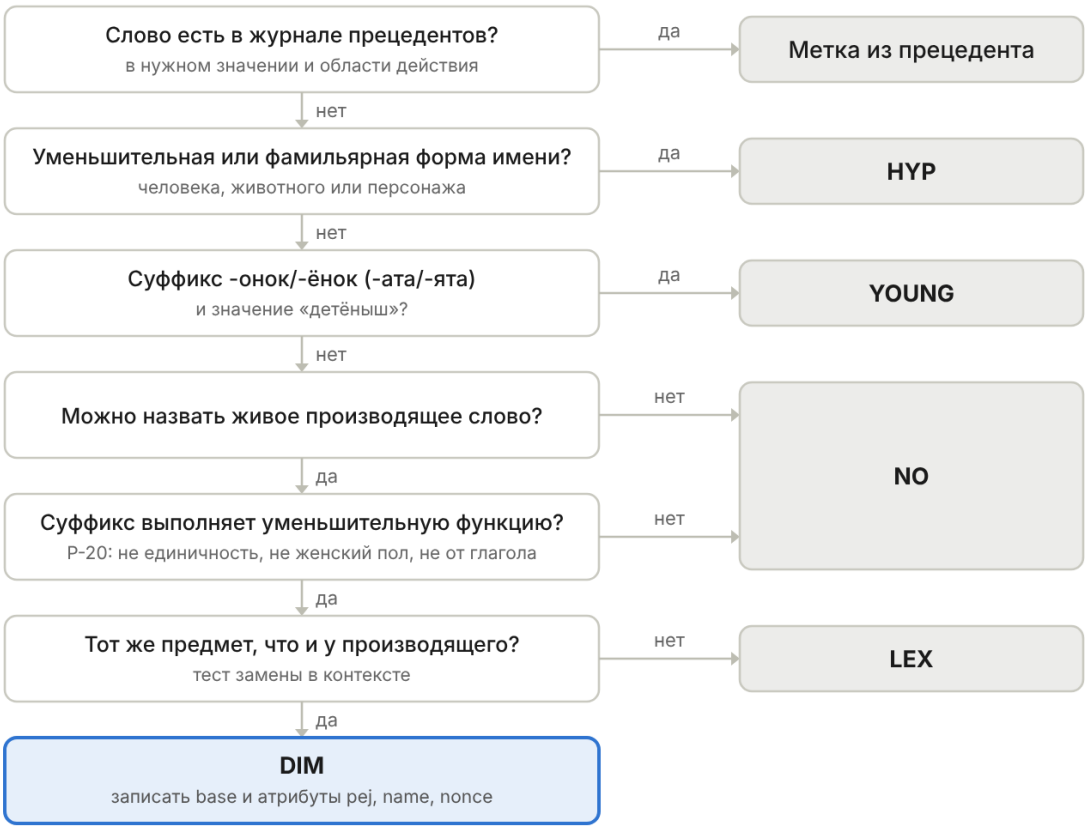
Шаг 5. При закрепленном самостоятельном/нейтрализованном значении назначить LEX; при иной деривационной функции или случайном совпадении — NO.

Шаг 6. Заполнить атрибуты; при недостаточных данных записать рабочую метку, unsure = 1 и вопрос для адъюдикации.

Приоритет относится к категории и значению, а не к написанию слова. Заглавная буква не превращает существительное в HYP. Метафорическое обращение не исключает DIM автоматически. Прецедент с недостаточным контекстом не считается окончательным решением.

Порядок шагов 3 (сначала HYP, затем YOUNG) относится к ручной разметке. В детекторе правило YOUNG проверяется раньше HYP (раздел 6, этап D). На практике категории не пересекаются: модель -онок/-енок не образует форм личных имен.

Первый ответ, уводящий вправо, даёт метку; дошли до низа — DIM



Книжная, разговорная или редкая база — повод для unsure и проверки закрытых соглашений P-01, P-03, P-22, а не автоматический LEX (раздел 2, признак 4).

5. Трудные случаи и журнал прецедентов

Новое решение получает дату, версию, область действия, контекст, источник и обоснование. Примеры из тестовой части не переносятся в детектор до завершения независимой оценки.

ID	Случай	Решение	Обоснование
P-01	бабушка, дедушка, девочка, мальчик	LEX	Устойчивое соглашение, это нейтральные названия с устаревшими, сниженными производящими словами.
P-02	книжка, морковка, речка, машинка (= маленькая машина)	DIM	Производящее нейтрально и денотат тот же; «разговорный» диминутив без ласки остается DIM (структурная функция).
P-03	ветка, маленький	LEX	Закрытое соглашение P-03; веточка ← ветка — DIM. Книжность базы сама по себе не доказывает лексикализацию.
P-04	ручка, ножка, глазок, конек, горка, лисичка, звездочка, грудка, тележка	По контексту	Часть тела, животное, маленький предмет — DIM (тележка = маленькая повозка; «ручки как

			ледышки», RUS-O_long_09). Другой предмет — LEX («покрутил ручку», «глазок микроскопа», коньки, детская горка, гриб лисичка, тележка в магазине, грудка — часть тела птицы, RUS-O_medium_05).
P-05	шарик = воздушный шарик; кроватка = детская кроватка; бутылочка = детская бутылочка	LEX (утвержден)	Сохраненное соглашение по специализированным значениям. Сам по себе подвид предмета не доказывает LEX. При недостаточном контексте unsure = 1; кукольная кроватка в исходном прецеденте — DIM.
P-06	-онок/-енок как имя героя (Мышонок Тим, Волчонок)	YOUNG; name = 1 (P-25)	Суффикс детеныша определяет категорию независимо от роли в сюжете; атрибут name = 1 (P-25). Но котеночек ← котенок — DIM.
P-07	щенок, ребенок, птенец	NO	Нет суффикса -онок/-енок и живого производящего. Птенцы (J081) — NO: схема YOUNG ограничена моделью -онок/-енок. Но ребеночек — DIM; детки — DIM по P-19.
P-08	зайчишка, муравьишка, мальчишка, девчонка	DIM; pej по контексту	Живая связь с базой; мальчишка ← мальчик, девчонка ← девочка. Суффикс не дает автоматической отрицательной оценки.
P-09	Имя персонажа с диминутивным суффиксом: Автомобильчик, Ежунчик, Мишутка	DIM + name	Имена от нарицательных баз: DIM + name. Обычные формы антропонимов относятся к HYP независимо от носителя. Новые аналоги исключения не добавляются автоматически.
P-10	Гипокористика на -к(а): Анька, Петька	HYP	Уменьшительные и фамильярные формы имен не делим на ласковые и сниженные. Полные и стандартные краткие имена (Анна, Маша) не размечаются.
P-11	-инк-: снежинка, тропинка	снежинка — NO; тропинка — DIM	-инк- в значении «одна единица» (снег → снежинка) не диминутивен; тропа → тропинка — тот же денотат. Общее правило для -к-/-инк- — P-20 (тип 3).
P-12	Составные через дефис: папа-мишка, крепко-крепко	По компоненту	Разобрать компоненты отдельно, указать целевой компонент. При одном релевантном компоненте токен получает его метку (включая LEX: Папа-мишка). Если релевантных компонентов несколько и метки различаются, не выбирать произвольный приоритет: unsure = 1 и адъюдикация.
P-13	Устойчивые имена	LEX	Имя собственное с утраченной

	фольклорных персонажей: Снегурочка		связью с производящим.
P-14	Иноязычные гипокористики: Тедди (RUS-T_short_03), Билли, Джонни	HYP + foreign = 1	HYP + foreign = 1 по проверенному перечню. Тедди → Тед — принятое проектное соответствие, не утверждение о полном официальном имени персонажа. Не восстанавливать полное имя без источника.
P-15	игрушка	LEX	Производящее (игра) назвать можно, но денотат другой — условие 3; base — игрушка (P-17)
P-16	мишка (медведь, плюшевый мишка)	LEX	Производящее — имя Миша, денотат другой (условие 3); медведь — синоним, а не производящее. pej не ставится. Мишутка как имя персонажа — по P-09.
P-17	Правило заполнения base	По метке	DIM — ближайшее морфологическое производящее (листочек → листок, не лист). LEX — само слово в начальной форме (девочка → девочка, коробка → коробка). YOUNG — название взрослого животного (поросенок → свинья, мышонок → мышь). HYP — полное или краткое имя (Аннушка → Анна, Тедди → Тед). Синоним производящим не считается (мишка → не медведь).
P-18	бедняжка (RUS-O_medium_05)	DIM	Живая связь с производящим (бедняга → бедняжка); решение адъюдикации пилота.
P-19	дочка, сынок, сыночек, детка, деточка; детки (мн. ч.)	DIM	Производящие (дочь, сын, дитя, дети) носитель называет, денотат тот же. base по P-17: деточка → детка, детка → дитя, детки → дети. Решения J004, J005, J019, J040, J042.
P-20	Суффикс -к- (с -очк-/-ечк-, -инк-): лапка, коробка, снежинка, малышка, стройка, кладовка, открытка, хрюшка	По функции суффикса (перечень ниже)	Классифицировать функцию; наличие однокоренного слова не определяет метку. Закрытые решения отмечены отдельно. LEX не интерпретируется как доказанная историческая стадия.
P-21	Живое производящее, другой денотат: кузнечик (кузнец), цветок (цвет), фантик (фант)	LEX	«Цветы» — NO в токенной схеме из-за отсутствия целевого суффикса в словоформе; «цветок» — LEX. Показатель отражает словоупотребления с целевой морфологией, а не число диминутивных лемм.
P-22	Производящее стилистически маркировано: пупок (пуп),	LEX	Сохраненные решения: пупок, какашка, хлебные крошки — LEX; крошка о ребенке — DIM. Это

	какашка (кака), хлебные крошки (кроха «крупица»)		лексически и контекстно ограниченные соглашения, а не общий запрет маркированной базы.
P-23	Авторские образования с уменьшительно-ласкательным суффиксом: сладенец, Нашенька, Ушастик, хорошечный	DIM по закрытому исключению; nonce проверяется независимо	Только перечисленные сладенец, Нашенька, Ушастик, хорошечный: база сладкий, наш, ушастый, хороший. Смена части речи и нестандартный суффикс допускаются явно, по решению J013/J018/J021/J036. Ласковость нового слова не является достаточным условием DIM. Новые случаи требуют отдельного решения; для анализа исключения выделяются по precedent.
P-24	Что значит «нет в словаре» для nonce	nonce = 1, если слова нет в словаре pymorphy3 (OpenCorpora)	Версии pymorphy3 и словаря, нормализация е/ё и регистр зафиксированы в разделе 6 («Версии инструментов»). Предсказанный анализ не считать словарной фиксацией.
P-25	Атрибут name у YOUNG и HYP	name ставится у DIM и YOUNG; у HYP не ставится	Названия детенышей часто служат именами персонажей (Медвежонок, Крольчонок, P-06); HYP — имя по определению.
P-26	Усечения без суффикса: зая	NO	Усечение без установленного суффиксального диминутивного образования; ласковое обращение само по себе не означает DIM.

P-20. Суффикс -к-: метку определяет функция суффикса

P-20 применяется после проверки контекстных прецедентов. Типы различаются по словообразовательной функции. При конкурирующих разборах нельзя выбирать первую подходящую строку: следует записать альтернативы и передать случай на адъюдикацию.

Тип	Что добавляет -к- (проверка)	Примеры из KidLit	Метка
0. -к- не выделяется	Живого однокоренного слова нет; отсечение даёт случайное слово.	ложка (не от «ложь»), шишка, бочка, лодка, шапка	NO
1. Уменьшительный	Диминутивная функция и допустимая база; разговорность без дополнительных оснований недостаточна.	лапка, книжка, машинка, лопатка (садовая), горка = кочка, тележка = маленькая повозка	DIM
2. Лексикализованное/закреплённое	Самостоятельное или нейтрализованное	коробка (короб), ручка двери, шляпка	LEX

значение	значение по контексту/закрытому прецеденту; историческая уменьшительность не предполагается автоматически.	гриба, детская горка, кошка (вид), карамелька (конфета), тележка в магазине	
3. Единичность	«Одна единица вещества или множества X».	снежинка, травинка, льдинка, бусинка	NO
4. Женский пол	«X женского пола».	малышка, внучка, соседка	NO
5. От глагола	Действие, результат или предмет для действия.	стройка, прогулка, остановка, кормушка, погремушка, хлопушка	NO
6а. Разговорный вариант субстантивата	X — существительное-субстантиват, предмет тот же.	кладовка (кладовая), столовка	DIM (как P-02)
6б. Сжатое словосочетание	Производящего существительного нет.	открытка (открытое письмо), электричка, газировка	NO
7. От междометия или звукоподражания	Производящее — междометие.	хрюшка (хрю), кукушка (ку-ку)	NO

Карамелька сохраняет LEX как закрытое решение J026/P-20. В J026 мотивировка ссылается на единичность, тогда как P-20 относит единичность к NO. До отдельного решения не обобщать этот пример. Для бинарного DIM/не DIM различие LEX/NO несущественно, для пяти классов и интерпретации LEX — существенно.

6. Логика детектора

Детектор повторяет тесты разметчика формально: суффикс → производящее → списки прецедентов. Простое правило «слово кончается на диминутивный суффикс» в KidLit даёт 1 736 лемм-кандидатов, и среди самых частотных: только, рука, грузовик, человек. Поэтому ключевым шагом является восстановление производящего.

Этап А. Кандидаты по суффиксу (для леммы; для слов вне словаря также для словоформы)

Часть речи	Суффикс (конец леммы)	Пример из корпуса → производящее
Сущ., м. р.	-ик, -чик, -ок/-ек/-ек, -очек/-ечек/-ичек, -ушек	домик → дом; кораблик → корабль; огонек → огонь; кусочек → кусок; цветочек → цветок
Сущ., ж. р.	-к(а), -очк(а)/-ечк(а)/-ичк(а), -	лапка → лапа; мамочка → мама; ладошка

	ушк(а)/-юшк(а), -оньк(а)/-еньк(а), -иц(а)	→ ладонь; капелька → капля; сестрица → сестра
Сущ., ср. р.	-к(о), -чк(о)/-ечк(о), -ышк(о)/-ушк(о), -иц(е)/-ц(е)/-ц(о)	окошко → окно; крылышко → крыло; солнышко → солнце; ведерко → ведро; крылечко → крыльцо
Сущ., уничиж.	-ишк(а/о), -онк(а)	зайчишка → заяц; рej только по контексту
Детёныши	-онок/-енок (лемма формы на -ата/-ята)	лисенок → лиса (YOUNG)
Прилагательные	-еньк-/-оньк-, -ехоньк-/-охоньк-/-ешеньк-	новенький → новый
Наречия	-онько/-енько, -оньку, -ечко/-очко/-очку, -шко	тихонько → тихо; потихоньку → тихо; немножко → немного

Этап В. Восстановление производящего

1. Отсечь суффикс с окончанием.
2. Построить варианты основы: обратить чередования (ч → к/ц/т, ж → г/з/д, ш → х/с, щ → ст/ск), добавить или убрать беглую гласную (дружок → друг, кусочек → кусок), добавить окончания того же рода и мягкий знак (ладошка → ладонь).
3. Кандидат базы проверяется в зафиксированной версии словаря pymorphy3/OpenCorpora. Совпадение части речи является обычным ограничением, кроме закрытого Р-23; род проверяется по правилам п. 4. Словарный разбор и предсказанный анализатором разбор различаются. Нужна проверка словообразовательной функции и значения.
4. **Морфологические проверки пары** (v3): одушевленность производного и базы совпадает (песок →/ пес); у неодушевленных сохраняется род (бочка →/ бок, стройка →/ строй); смена мужского рода на женский у одушевленных дает феминитив, а не диминутив (медведь → медведица; проверяется по лексеме, а не по выбранному разбору); имя собственное не может быть базой нарицательного (мартышка →/ Марта), а если производное само является именем, оно получает HYP (Анютка ← Аня).
5. **Частотная защита:** база не должна быть более чем вдвое реже производного по частотному словарю Ляшевской — Шарова (солнце →/ солонка). Для каждого суффикса задана минимальная длина основы.
6. Второй источник — пары «производящее → производное» из DerivBase.Ru (Vodolazsky 2020). Он нужен для случаев, где отсечение не срабатывает: зайчик → заяц, мамуля → мама. Пара из DerivBase принимается, только если основы совместимы с точностью до чередования, беглой гласной или усечения (пуговица → пуговка,

окошко → окно); так отсекаются случайные пары (шина →/ шишка, крона →/крошка, птица →/птенец).

Этап C. Списки прецедентов (перекрывают этап B)

- lex_list — лексикализованные (P-01, P-03, P-13).
- no_list — ложные срабатывания, у которых отсечение случайно дает слово (кабачок → «кабак»).
- context_list содержит леммы и значения P-04/P-05 и другие неоднозначные случаи. Детектор возвращает предварительную метку, needs_review = 1 и основание; до контекстного решения она не считается окончательной.
- Словарь прецедентов версионируется: dim_lexicon_v3.csv — 81 лемма, оцениваемая версия v3 (без новых лемм, встречающихся в test); dim_lexicon_v3.1.csv — 104 леммы, рабочая версия v3.1 для разметки корпуса.

Этап D. Порядок назначения метки (первое сработавшее правило побеждает, его rule_id записывается)

1. R0 Словоформа без целевого суффикса → NO (P-21): цветы (лемма цветок), меньше (лемма маленький).
2. R1 Списки прецедентов → метка из списка.
3. R2 Модель названия детеныша -онок/-енок с соответствующими формами множественного числа и значением → YOUNG. При вторичном уменьшительном суффиксе (котеночек) → проверка DIM. Для поросенок база свинья задается семантическим соответствием, а не правилом отсечения.
4. R3 Подтвержденная антропонимическая уменьшительная/фамильярная форма → HYP; граммема Name и PER_NAME сами по себе недостаточны. Иноязычные формы учитываются по отдельному проверенному списку.
5. R4 Подтверждены диминутивная функция и допустимая база → предварительный DIM; если значение, имя или исключение не устанавливаются автоматически, needs_review = 1. nonce вычисляется отдельной словарной проверкой, name — по функции наименования в контексте.
6. R5 Подтверждена недиминутивная функция → NO. Если база не восстановлена автоматически, но диминутивный анализ возможен, назначается needs_review = 1, а не окончательное NO. Результаты автоматической и проверенной человеком систем оцениваются отдельно.

Известные ловушки в данных KidLit (найдены при подготовке инструкции):

- Ошибки лемматизации: «ждал **белок**» (RUS-O_long_07) получает лемму *белок*, хотя это род. мн. от *белка*. Поэтому детектор проверяет альтернативные разборы pymorphy3, а не только выбранную лемму.
- Форма *деток* получает лемму *ребеночек*. Это правильный DIM, но производящее надо искать по словоформе (дети).
- Граммема Name ошибочно стоит у сколька и столька. Для R3 нужна проверка антропонимической функции и стоп-список.
- Наречия на -ко (*крепко*, *громко*, *далеко*) попадают в кандидаты. Кандидатом считается только полный суффикс (-онько, -ечко, -шко), а не одно -ко.
- Слова вне словаря среди самых частотных — продуктивные диминутивы (енотик, бегемотик, колесик, вертолетик). Их нельзя отбрасывать: для них основа ищется по словоформе.
- **Смена рода у диминутива:** коленка (колено), табуретка, жилетка отсекаются правилом рода для неодушевленных — известное ограничение v3.
- **Короткая основа:** ямка не проходит порог минимальной длины основы — известное ограничение.
- **конечно** — не диминутив (нет суффикса из этапа A), хотя при разметке его отмечали как DIM (J009, J077, J078).
- **меньше** (лемма маленький) — NO по R0 (J031, J049).

Выход детектора: book_id, kidlit_id, sent_id, tok_id, token, lemma, pos, cand_suffix, base_lemma, base_source, det_label, rule_id, pej, name, nonce, foreign, needs_review. Пустое значение означает «не проверено / неприменимо» по схеме поля, а не автоматически 0.

Версии инструментов: razdel 0.5.0; spaCy ru_core_news_sm 3.8.0; pymorphy3 2.0.6 со словарем pymorphy3-dicts-ru 2.4.417150.4580142 (OpenCorpora); DerivBase.Ru commit 0f246dc (v001.00-connections.zip); частотный словарь Ляшевской — Шарова (2009). Нормализация: ё → е, нижний регистр.

7. Порядок работы и формат таблицы

Разметка идет в двух режимах, и у каждого своя цель. Оба режима — вслепую: разметчик не видит метку детектора и метки коллеги.

Режим	Зачем	Что делает разметчик
Сплошное чтение книги	Оценка полноты (recall) детектора	Читает текст подряд и отмечает все DIM, HYP и YOUNG. LEX и NO не отмечает.
Проверка	Оценка точности	Получает список слов с контекстом и присваивает

кандидатов	(precision) детектора	каждому одну из пяти меток: DIM, LEX, HYP, YOUNG или NO.

Алгоритм на одно слово

1. Прочитать предложение целиком.
2. Пройти схему из раздела 4 сверху вниз и остановиться на первой подходящей метке.
3. Записать base по P-17; у DIM проверить pej, name и nonce, у YOUNG — name, у HYP — foreign. pej отражает подтвержденную контекстом пренебрежительную оценку, а не сам суффикс. Неопределенное значение требует unsure и комментария.
4. Если слово есть в журнале прецедентов, следовать прецеденту и указать его ID в precedent.
5. В режиме проверки кандидатов каждому кандидату ставится рабочая метка; сомнение отмечается unsure = 1. В режиме сплошного чтения нецелевые слова остаются пустыми только после проверки текста.

Таблица разметки (один файл на разметчика, одна строка на словоупотребление):

Колонка	Заполняет	Содержание
kidlit_id, book_id, sent_id, tok_id	Скрипт	Адрес слова в `tokens.parquet`
token, lemma, context	Скрипт	Слово, лемма, предложение со словом в [скобках]
label	Разметчик	DIM / LEX / HYP / YOUNG / NO
base	Разметчик	По P-17; поле неоднородно: у LEX это лемма самой единицы, у YOUNG — семантическое соответствие взрослого животного, а не всегда морфологическое производящее.
pej, name, nonce, foreign	Разметчик	0 или 1 (foreign — только у HYP)
precedent	Разметчик	ID прецедента, если применён; латинская P (P-04, не кириллическая Р)
unsure, comment	Разметчик	0/1 и свободный текст

При сплошном чтении скрипт дает таблицу всех слов книги, и разметчик заполняет label только у нужных. Пустой label здесь означает «не DIM, не HYP, не YOUNG».

Согласие вычисляется по независимым исходным разметкам до обсуждения. Для кандидатов указываются к по пяти категориям и DIM/не DIM, объем и матрица ошибок. Для сплошного чтения оценивается согласие выделения

токенов и отдельно их классификации; набор сравниваемых токенов должен быть описан.

Файлы разметчиков после подсчета не редактируются. Согласие считается по исходным файлам, а решения адъюдикации записываются только в adjudication.xlsx (колонки final_label, final_base, final_pej, final_name, final_nonce, final_foreign, precedent, decision_comment, confirmed; золотые метки собираются только при confirmed = 1 во всех строках). Итоговую разметку собирает скрипт. Если файлы изменены после адъюдикации, скрипт предупреждает.

8. Контрольные примеры

Инструкция считается понятой, когда оба разметчика независимо разметили 20 примеров и совпали с ключом. Размечается слово в [скобках]. Сначала разметьте все 20, потом сверьтесь с ключом.

№	Контекст	Книга
1	Ой, [ручки] как ледышки!	RUS-O_long_09
2	…покрутил [ручку].	RUS-O_long_07
3	…сны [мышатам] хорошие снились…	RUS-O_long_06
4	[Анька] провинилась.	RUS-O_long_25
5	…сигналит [грузовик].	RUS-O_long_08
6	Они [тихонько] переговаривались друг…	RUS-O_medium_01
7	…язык [новеньким] снежинкам…	RUS-O_long_07
8	…новеньким [снежинкам]…	RUS-O_long_07
9	…по [тропинке]…	RUS-O_long_07
10	…с [горки]?	RUS-O_long_07
11	[Мамочка], давай покатаемся…	RUS-O_long_07
12	Старый [Автомобильчик] так давно…	RUS-O_medium_01
13	…четыре [котофеечки].	RUS-O_long_26
14	…голодных [деток].	RUS-O_long_06
15	[Зайчишка] очень любил морковку.	RUS-O_short_02
16	Зайчишка очень любил [морковку].	RUS-O_short_02
17	…ты, [Мишутка], — сказал…	RUS-O_long_15
18	…[глазок] микроскопа.	RUS-O_long_07
19	…закрыли [глазки].	RUS-O_long_06
20	…услышали [щенята] странный шум.	RUS-O_long_06

Ключ к практической разметке

№	Метка	base / атрибуты	Правило
1	DIM	рука	P-04: часть тела
2	LEX	ручка	P-04: другой предмет
3	YOUNG	мышь	-ята, детёныши
4	HYP	Анна	P-10

5	NO	—	Нет производящего с тем же денотатом
6	DIM	тихо	Наречие на -онько
7	DIM	новый	Прилагательное на -еньк-
8	NO	—	P-11: -инк- «единица»
9	DIM	тропа	P-11
10	LEX	горка	P-04: детская горка
11	DIM	мама	Признаки DIM раздела 2
12	DIM	автомобиль; name = 1	P-09
13	DIM	котофей; nonce = 1	Нет в словаре
14	DIM	дети	P-19: детки → дети
15	DIM	заяц; pej = 0; name в контрольном примере не оценивается	P-08: pej только при пренебрежительном контексте; name требует полного текста книги
16	DIM	морковь	P-02
17	DIM	Миша; name = 1; закрытое исключение P-09	P-09
18	LEX	глазок	P-04
19	DIM	глаз	P-04
20	NO	—	P-07: форма от щенок

9. Спорные случаи из адъюдикации

ID / слово	Источник и контекст	Итог в XLSX	Уточнение для новой схемы
J001 · бутылочку	Строка 2; RUS-O_medium_04. «И [бутылочку] свою Неохотно…»	LEX; base: бутылочка	LEX по P-05 сохранено как соглашение; base исправлен по P-17 (было бутылка). Назначение бутылочки требует расширенного контекста.
J004 · детка	Строка 5; RUS-O_medium_04. «Уплывает [детка] в сон,…»	DIM; base: дитя	DIM сохранено как исключение из прежнего запрета книжной базы дитя.
J008 · клопик	Строка 9; RUS-O_medium_04. «…мамин [клопик], Ты чего…»	DIM; base: клоп	Метафорическое обращение к ребёнку не отменяет диминутивную структуру клоп → клопик.
J011 · крошки	Строка 12; RUS-O_medium_04. «…нашей [крошки] Целых две…»	DIM; base: кроха	Крошка о ребёнке — DIM; сопоставить J028: хлебные крошки — LEX, `base = крошка`.
J013 · Нашенька	Строка 14; RUS-O_medium_04. «Наша [Нашенька]»	DIM; base: наш	Закрытое исключение P-23. Смена части речи допускается явно; исходное `nonce = 1`. Атрибут `name` не выводится только из прописной буквы.
J018 · сладенец	Строка 19; RUS-O_medium_04. «Спи, [сладенец]»	DIM; base: сладкий	Закрытое исключение P-23. Не распространять DIM автоматически на ласковые

			обращения или все образования на -енец.
J021 · хорошечный	Строка 22; RUS-O_medium_04. «…такой [хорошечный]»	DIM; base: хороший	Решение P-23. Список суффиксов детектора не является исчерпывающим определением категории.
J026 · карамельку	Строка 27; RUS-O_long_10. «…небольшую [карамельку]»	LEX; base: карамелька	LEX сохранено как закрытое решение P-20; обоснование через единичность конкурирует с NO (P-20, тип 3). base = карамелька по P-17.
J027 · кладовке	Строка 28; RUS-O_long_30. «…уютной [кладовке] На длинной…»	DIM; base: кладовая	Закрытое соглашение для кладовка. Наличие базы кладовая не означает автоматического DIM для всех разговорных субстантиватов.
J032 · малышка	Строка 33; RUS-T_short_10. «…пропищала [малышка] Лили, —…»	NO; base не заполнено	NO по феминитивной функции. Это граница принятой схемы, а не отрицание ласковой функции в речи.
J033 · Папа-мишка	Строка 34; RUS-T_medium_13. «…ответил [Папа-мишка]»	LEX; base: мишка	Метка определяется по компоненту мишка. Правило дефисных токенов охватывает LEX, а не только DIM.
J034 · поросенок	Строка 35; RUS-O_medium_12. «…потом [поросенок] Петр понял, …»	YOUNG; base: свинья	Свинья — семантическая база, а не результат морфологического отсечения.
J036 · Ушастика	Строка 37; RUS-T_long_06. «…себе [Ушастика]»	DIM; base: ушастый	Закрытое исключение P-23
J037 · фантики	Строка 38; RUS-O_long_34. «…валялись [фантики] от конфет»	LEX; base: фантик	LEX сохранено; base исправлен по P-17 (было фант). Фант можно указывать в комментарии как гипотезу мотивации.
J043 · фонарик	Строка 44; RUS-T_long_05. «…живой [фонарик] – маленький…»	DIM; base: фонарь	Метафорическое название светлячка не означает автоматической лексикализации.
J054 · Машенька	Строка 55; RUS-O_medium_04. «…да [Машенька]»	HYP; base: Маша	Базой может быть краткое имя; требование только полного имени недопустимо.
J063 · Бегемотик	Строка 64; RUS-O_long_01. «[Бегемотик] едва не…»	DIM; base: бегемот	Прописная буква не доказывает `name = 1`. Исторически `name = 0`; для пересмотра нужен полный контекст книги.
J074 · цветы	Строка 75; RUS-T_long_02. «…весенние [цветы]»	NO; base не заполнено	В принятой токенной схеме NO; не смешивать с классификацией леммы цветок = LEX.
J076 · Горка	Строка 77; RUS-O_long_03. «[Горка]!»	DIM; base: гора	Историческое решение P-04 сохраняется. Для нового независимого решения требуется

			контекст, позволяющий различить возвышенность и сооружение.
J081 · птенцы	Строка 82; RUS-T_long_08. «…летать, [птенцы] едят только…»	NO; base не заполнено	NO в морфологически ограниченной схеме YOUNG. Учёт молодых животных в целом потребует отдельной схемы, включающей птенцы и щенята. Прецедент P-07.

Изменения в v0.3 (по итогам пилота)

Пилот: RUS-O_medium_05 и RUS-T_short_03, 1 000 слов и 103 кандидата. Согласие до адъюдикации: сплошное чтение — F1 по DIM 0,975, к 0,970; проверка кандидатов — к 0,967 (5 меток), 0,960 (DIM / не DIM). Расхождений — 6.

- Утверждены все прецеденты со статусом «предложение» (P-05, P-08).
- P-04 дополнен: грудка (часть тела птицы) — LEX.
- Новые прецеденты: P-14 (иноязычные гипокористики), P-15 (игрушка — LEX), P-16 (мишка — LEX), P-17 (правило base), P-18 (бедняжка — DIM).
- Новый атрибут foreign (для HYP).
- Из примеров атрибута nonce убран Шпунчик (нет живого производящего — NO); в P-09 у Мишутки производящее — Миша.
- Раздел 7: правило P-17 для base, латинская P в номерах прецедентов, файлы разметчиков после подсчета не редактируются.

Изменения в v0.4 (по итогам адъюдикации золотой выборки)

Адъюдикация 19–20.10.2026: 81 случай (J001–J081). Согласие до адъюдикации: сплошное чтение — F1 по DIM 0,904; проверка кандидатов — к 0,736 (5 меток) и 0,760 (DIM / не DIM).

- Новые прецеденты P-19–P-26; P-20 — единый прецедент для суффикса -к- (9 типов реализации).
- P-04: добавлена тележка. P-05: добавлена детская бутылочка. P-11: ссылка на P-20.
- Атрибуты: name — у DIM и YOUNG (P-25); nonce — по словарю pymorphy3 (P-24).
- Изменения списков детектора версионируются. Решения по test нельзя использовать для настройки системы, качество которой затем сообщается на том же test как независимое.

Изменения в v0.5

- LEX — операциональный класс (раздел 3): исторический статус без отдельного источника не утверждается (в v0.4 LEX был описан как класс только бывших диминутивов).
- Признак 4 — диагностика; условие 4 из статьи применяется через закрытые соглашения P-01, P-03, P-22 (раздел 2).
- Схема решения (раздел 4) обновлена: добавлен вопрос о функции суффикса (P-20); HYP охватывает формы имен людей, животных и персонажей; маркированная база не дает автоматического LEX.
- Раздел 6 согласован с детектором v3 и статьей: правило R0, порядок R2 YOUNG → R3 HYP, морфологические проверки, частотная защита, фильтр пар DerivBase, версии словаря прецедентов и инструментов, новые ловушки.
- P-06: name = 1 (P-25). P-07: добавлен птенец (J081). P-20: бабушка перенесена из типа 2 (относится к P-01), добавлена кошка (вид), частоты из примеров убраны; кошка в разделе 3 обоснована.
- Ключ контрольных примеров: № 14 — P-19; № 15 — однозначный ключ без name.
- Раздел 9 и adjudication.xlsx согласованы: base по P-17 (J001, J016, J026, J037), единый формат precedent, J023 — no_list, J081 — P-07, confirmed = 1 во всех 81 строке.
- Добавлен список литературы.

Литература

1. Васильева А.В., Резанова З.И. Эмоциональность диминутива: соотношение с оценочностью, частотностью, возрастом усвоения, контекстуальной маркированностью // Вестник Томского государственного университета. 2019. № 445. С. 22–31. DOI: 10.17223/15617793/445/3.

2. Воейкова М.Д. Структурные функции диминутивов в современном русском языке и продуктивность их употребления // Вопросы языкознания. 2020. № 5. С. 38–56. DOI: 10.31857/0373-658X.2020.5.38-56.

3. Земская Е.А. Современный русский язык. Словообразование. М.: Просвещение, 1973. 304 с.

4. Ляшевская О.Н., Шаров С.А. Частотный словарь современного русского языка (на материалах Национального корпуса русского языка). М.: Азбуковник, 2009. 1087 с.

5. Русская грамматика. Т. 1 / гл. ред. Н.Ю. Шведова. М.: Наука, 1980. 783 с.

6. Dressler W.U., Merlini Barbaresi L. Morphopragmatics of diminutives and augmentatives: on the priority of pragmatics over semantics // Perspectives on Semantics, Pragmatics, and Discourse / ed. by I. Kenesei, R.M. Harnish. Amsterdam: John Benjamins, 2001. P. 43–58. DOI: 10.1075/pbns.90.07dre.

7. Korobov M. Morphological analyzer and generator for Russian and Ukrainian languages // AIST 2015. CCIS, vol. 542. Springer, 2015. P. 320–332. DOI: 10.1007/978-3-319-26123-2_31.

8. Vodolazsky D. DerivBase.Ru: a derivational morphology resource for Russian // Proc. of LREC 2020. 2020. P. 3937–3943.